

예측애널리틱스 3 차과제

2022170841 최정우

Introduction

현대 공급망 관리(Supply Chain Management, SCM)에서 **수요 예측(Demand Forecasting)**은 재고 비용 최소화와 서비스 수준 극대화라는 두 마리 토끼를 잡기 위한 핵심 요소다. 특히 물류 배송 데이터는 기업의 활동성을 직접적으로 나타내는 지표로, 정확한 예측은 효율적인 자원 배분과 운영 스케줄링의 근거가 된다.

이 과제의 목적은 2020년부터 2025년까지의 실제 공급망 인도(delivery) 데이터를 분석하여, 복잡한 패턴을 가진 시계열 데이터에 최적화된 예측 모델을 구축하는 데 있다. 단순 통계 모델부터 계절성을 반영한 고급 시계열 모델까지 다양한 방법론을 비교하여, 향후 10 시점 이상의 수요를 가장 정확하게 예측할 수 있는 모델을 제안하고자 한다.

Data Description

본 분석에 사용된 데이터셋(supply_chain_deliveries.csv)은 2020년 1월부터 2025년 6월까지 약 5년 6개월간의 공급망 물동량 정보를 담고 있다.

관측 기간: 2020-01-02 ~ 2025-06-30

주요 변수: WorkDate: 인도 발생 일자

Customer: 주요 고객사 (Amazon, Costco, Home Depot 등)

Location: 거점 위치 (Chicago, Los Angeles 등)

OrderCount: 발생한 주문의 수량

TotalRevenue: 해당 인도를 통해 발생한 총 매출액

핵심 예측 대상(Target Variable)은 '**월간 총 주문수(Monthly Total OrderCount)**'이다.

일별 데이터는 변동성이 크고 불규칙한 노이즈가 많으므로, 전략적 의사결정에 적합한 월별(Monthly) 단위로 데이터를 리샘플링하여 분석을 수행한다. 데이터의 수준(Level)이 높아짐에 따라 변동폭이 커지는 이분산성 여부를 판단하여, 필요시 로그 변환(Log Transformation)을 적용한 뒤 모델링을 진행한다.

Modeling Approach

예측 성능의 객관적인 비교를 위해 다음과 같이 단계별 모델링을 수행한다.

Binary Variable Method: 월별 더미 변수를 활용한 계절성 모사

Trigonometric Method: 삼각함수(Sin, Cos)를 이용한 주기성 모델링


지수 평활법 (Exponential Smoothing): Simple (SES) 및 Double Exponential Smoothing (DES)을 통한 추세 반영 확인

Holt-Winters (Additive/Multiplicative): 가중치 파라미터(alpha, beta, gamma) 튜닝을 통한 추세 및 계절성 통합 모델링



Seasonal ARIMA (SARIMA): 자기회귀 및 이동평균 기반의 정교한 시계열 모델링

최종적으로 각 모델별로 최소 10 시점 이상의 Extrapolation 예측을 수행하고, **적절한 measuremnet** 를 활용하여 예측력을 평가할 예정이다.

EDA




x-axis : year , y-axis : order count 로 하는 plot 을 그린 결과, 시간이 지날수록 mean 이 증가하고(Trend) variation 폭이 넓어지는 것을 확인할 수 있다




더 자세히 보기 위해 stanard deviation 을 중심으로 plot 을 그려본 결과 좌측의 그래프는 시간이 지날수록 mean 이 증가하고 std 도 빨간색 추세선과 동시에 증가함을 알 수 있고 오른쪽의 그래프는 연도별 평균과 std 이 양의 상관관계를 가짐을 scatter plot 으로 확인할 수 있다

=> Log transformation 을 진행



Log transformation 을 통해 변동폭이 일정해진 시계열 plot 을 얻었습니다. 후에 Transformed data 에 모델을 적용해보겠다.



EDA 파트의 마지막으로 original Ordercount 에 decomposition 을 진행해본 결과 **increasing TR,Seasonal variatioin** 이 뚜렷하게 존재함을 다시 한번 확인할 수 있다.

Preprocessing

- aggregation : 일별 ordercount -> 월별 ordercount 로 aggregate.

데이터양과 분산을 줄여 stable 한 분석을 가능하게끔 해준다.

- missing value 처리 : time series 데이터의 연속적인 흐름을 끊기게 하지 않기 위해서 결측치 전후 월의 mean 으로 결측치를 채우는 linear interpolation 을 사용한다.

- Log transformation : EDA 에서 필요성을 역설했듯이 log transformation 을 통해 변동폭이 커지는 이분산성을 완화해준다.

-feature engineering : Modeling Approach 부분에서 제안한 모델을 사용하기 위해 feature 을 미리 만들어준다.

1)**Binary Variable Method:** 월별 계절성을 포착하기 위해 Monthly Dummies를 생성함. 다중공선성 방지를 위해 12월을 기저 집단(Base Group)으로 설정하여 11개의 가변수를 운용함.

2)**Trigonometric Method:** Fourier Series를 활용하여 계절성을 연속적인 함수로 모델링함. 1차 및 2차 하모닉스(sin, cos 항)를 생성하여 복합적인 계절 패턴을 반영함.

3)**Holt-Winters:** statsmodels 패키지의 ExponentialSmoothing 함수를 사용하여 별도의 피쳐 생성 없이 모델 내부의 평활 계수(alpha, beta, gamma) 최적화를 통해 예측을 수행함.

4)**SARIMA:** Box-Jenkins 방법론에 따라 ADF Test 를 통한 정상성 확인 및 차분(d, D) 단계를 거침. 이후 ACF/PACF 분석 및 Grid Search 를 통해 최적의 모델 차수를 식별함.

#1. Binary 변수 방법을 이용하여 모델링을 수행하고, testing data 를 활용하여 예측 성능을 평가하시오.


- 마지막 12 개월을 test set 으로 지정해서 예측 성능을 보겠다.

- 성능 지표는 RMSE 와 MAPE 를 사용

--- Binary Variable Method 성능 평가 ---

RMSE: 2081.96

MAPE: 3.03%



RMSE: 2082 -> 평균적으로 +- 2082 개의 인도물량 오차가 생김 -> 안전재고에 반영. 전체 규모 대비 큰 값은 아님


MAPE: 3% -> 실제 인도물량과 예측 인도물량의 차이가 약 3% : 매우 우수한 모델임.

Insight

Binary Variable 을 통해 Trend 와 Seasonal Variation 을 모두 잘 잡아내는 우수한 모델을 만들 수 있었다. 제시된 RMSE 와 MAPE 값은 물류현장에서 안전 재고량을 최소화하고 운영 효율성을 극대화할 수 있는 강력한 근거를 제시한다.

#2. Trigonometric 방법을 이용하여 모델링을 수행하고, testing data 를 활용하여 예측 성능을 평가하시오.

- 1차 하모닉스만 사용하는 모델과 2차 하모닉스까지 사용하는 모델을 만들어 비교하고 더 우수한 모델을 사용하겠다.



Model 1 (1 Harmonics) - RMSE: 5898.09, MAPE: 7.66%

Model 2 (2 Harmonics) - RMSE: 5102.87, MAPE: 6.51%

Model 2 가 Model 1 에 비해 1.1%의 예측 오차를 줄일 수 있기에 더 우수한 모델이라 생각한다. 왜냐하면 변수를 추가해서 얻는 모델의 복잡성보다 인도물량 오차 1.1%를 잡아내는 것이 더 중요하기 때문이다.

하지만 binary model 에 비해 RMSE 는 약 2.5 배, MAPE 는 약 2.2 배이다.

1. 파라미터의 개수. Trigonometric model 은 하모닉스 변수 4 개를 사용하는것에 비해 Binary model 은 dummy 변수를 11 개를 사용하기 때문에 계산량, 복잡도, 설명력 모두 높을 수 밖에 없다.
2. 부드러운 곡선형태의 데이터가 아니기 때문에 실제 data 의 spiky 한 점들을 따라가기 힘들다.

따라서 데이터셋의 특성상 binary model 을 사용하는 것이 더 바람직하다.

#3. Simple Exponential Smoothing과 Double Exponential Smoothing 방법을 적용하여 예측력을 비교하시오.

- 최소 10시점 이상 예측할 것
- 각 방법의 하이퍼파라미터를 다양하게 설정하여 실험한 뒤, 최적의 하이퍼파라미터 값을 선택하여 결과를 제시할 것

- SES 와 DES 는 계절성 반영 기능이 없음 -> 예측력 안 좋을 것

- grid search 를 이용해 alpha,beta(DES 에서만)를 0.1~0.9 까지 0.1 씩 늘려가며 MAPE 를 확인해보겠다.(MAPE 가 클 것이라 생각해 RMSE 까지는 안보겠다)

=== SES 하이퍼파라미터 실험 결과 (전체) ===		
Alpha (Level)	MAPE(%)	
0	0.1	25.05
1	0.2	25.97
2	0.3	27.65
3	0.4	29.30
4	0.5	30.63
5	0.6	33.19
6	0.7	35.82
7	0.8	37.67
8	0.9	38.92

=== DES 하이퍼파라미터 상위 10개 결과 (MAPE 기준 오름차순) ===			
Alpha (Level)	Beta (Trend)	MAPE(%)	
0.1	0.2	24.98	
0.1	0.3	24.98	
0.2	0.1	25.23	
0.1	0.4	25.50	
0.1	0.5	25.95	
0.2	0.2	26.04	
0.1	0.6	26.16	
0.1	0.1	27.49	
0.1	0.7	27.76	
0.1	0.8	28.04	

SES 실험 해석 : 표 1 을 보면 alpha 값이 0.1 일 때 오차가 25.05%로 가장 낮고, alpha 가 커질수록(즉, 최근 데이터에 민감하게 반응할수록) 오차가 최대 38.92%까지 증가한다. 이는 이 데이터셋이 계절성에 의해 단기 변동성이 크기 때문에, 최근 데이터에 휩쓸리지 않고 차라리 과거의 전체적인 평균 수준(alpha=0.1)을 유지하는 편이 더 낫다는 것을 의미한다.

DES 실험 해석 : 표 2 의 다양한 조합을 실험한 결과, 추세 파라미터 beta 가 0.2~0.3 수준일 때 오차가 가장 낮았다(24.98%). 하지만 SES 의 최적 성능(25.05%)과 큰 차이가 없는데, 이는 본 데이터셋의 구조가 단순한 직선 추세(Trend)만으로는 설명될 수 없고 주기적인 등락(Seasonality)이 더 지배적이기 때문이다."

예상대로 계절변동을 잘 반영하지 못하는 SES,DES 는 이 데이터셋에 적합한 모델이 아님을 알 수 있다.

#4. Additive Holt-Winters, Multiplicative Holt-Winters, Seasonal ARIMA 방법을 적용하고, 최소 10 시점 이상 예측한 뒤 각 방법의 예측력을 비교하시오.

Additive HW, Multiplicative HW

- 파이썬의 statsmodels 패키지의 ExponentialSmoothing 함수를 사용해서 optimal alpha,beta,gamma 를 구해보았다.

결과) Alpha (Level): 0.09937836699168437

Beta (Trend): 0.09937836699168437

Gamma (Seasonal): 0.0

- Additive Holt-Winters model : 계절적 변동폭이 일정하다고 가정

- Multiplicative Holt-Winters model : 데이터의 수준(Level)이 커질수록 계절적 변동폭도 비례해서 커진다고 가정

EDA 에서 이미 데이터는 시간이 지날수록 변동폭이 커짐을 확인했기에 Multiplicative Holt-Winters model 이 더 적합할 것으로 예상된다.

SARIMA

- (p,d,q)(P,D,Q)를 정하는 것이 우선 과제이다

- 최적의 SARIMA 모델을 구축하기 위해 두가지 objective function 을 기준으로 Grid search 진행

1. AIC 가 가장 낮은 모델 2. MAPE 가 가장 낮은 모델

```

=====
🏆 [Model 1] 통계적 최적화 (Minimum AIC) 모델
=====
파라미터: order=(0, 0, 0), seasonal_order=(1, 0, 0, 12)
AIC Value: -128.47
Test MAPE: 4.24%

=====
🏆 [Model 2] 실무적 최적화 (Minimum MAPE) 모델
=====
파라미터: order=(1, 1, 1), seasonal_order=(1, 0, 1, 12)
AIC Value: -109.75
Test MAPE: 3.25%

```

통계적 강건성(AIC 최소화) 기준:

탐색 결과 (0,0,0) x (1,0,0,12) 모델이 최저 AIC(-128.47)를 기록하며 통계적으로 가장 효율적인 모델로 선정되었다. 이 모델은 파라미터를 최소화하여 과적합(Overfitting)을 방지하는 안정적인 구조를 가지며, 테스트 데이터에 대해 4.24%의 준수한 예측 오차율(MAPE)을 보였다.

단기 예측 정확도(MAPE 최소화) 기준:

실제 비즈니스 관점에서의 오차를 최소화하기 위해 MAPE 를 기준으로 재탐색한 결과, (1,1,1) x (1,0,1,12) 모델이 오차율 3.25%를 기록하며 가장 우수한 예측력을 보였다. 이 모델은 차분(Differencing)과 이동평균(MA) 성분을 추가하여 데이터의 단기 변동성을 더 세밀하게 포착하였다. (AIC: -109.75)

conclusion)

AIC 최소화 모델은 장기적인 관점에서 모형의 안정성을 보장하지만, 공급망 인도 수량 예측과 같이 단기적인 수요(향후 12 개월)에 즉각적으로 대응해야 하는 실무적 환경에서는 예측 오차를 약 1%p 더 줄인 **MAPE 최소화 모델 (1,1,1) x (1,0,1,12)을 최종 예측 모델로 채택하는 것이 합리적이다.**

2 개의 HW 모델과 SARIMA 모델의 예측력을 MAPE, RMSE 을 통한 정량적 분석과 plot 을 통한 시각적 분석을 동시에 진행해보자.

Measurement – AIC 가 아닌 MAPE 채택 이유


AIC 를 이용하면 robust 하고 장기적 관점에서의 우수한 모델을 구축가능하지만

MAPE 를 이용해 **단기적인 관점에서 정확한 수요예측을 하는것이 demand forecasting 관점에서 더 적합하다.**

=== 예측 모델 성능 비교 결과 ===

Model	RMSE	MAPE(%)
-------	------	---------

Additive HW	4449.83	5.67
Multiplicative HW	2194.51	3.22
SARIMA (1,1,1 x 1,0,1)	2559.23	3.73



1. Multiplicative HW - MAPE(3.22%) 가장 우수한 예측력

파란색 선이 actual target 을 가장 잘 따라간다. 특히 급격히 꺾이는 peak 와 through 에서의 변화를 잘 잡아내었다. 이는 데이터가 **delivery 수준이 높아질수록 (TR) seasonal variation 이 함께 커지는 multiplicative** 특성을 뚜렷하게 가지고 있기에 이 특성이 잘 반영된 것이라 해석할 수 있다.

2. SARIMA - MAPE(3.73%)

SARIMA 는 AR(autocorr)과 MA(moving average), 12 개월전의 seasonal variation 까지 수식에 포함해 계산한다. 이 방법으로 Multiplicative HW 와 근접한 우수한 예측을 할 수 있다. 다만, 이 데이터는 Multiplicative HW 가 더 적합한 모델이기에 차선택으로 선택할 수 있다.

3. Additive HW - MAPE(5.67%)

Additive HW 는 seasonal variation 이 일정하다고 가정하기 때문에 delivery 양이 커진 2025 년 validation(test) 구간에서는 실제 수요보다 낮게 예측하는 underestimation 이 발생하였다.

#5. Additive Holt-Winters 와 Multiplicative Holt-Winters 방법에 대하여, 가중치 파라미터(alpha, gamma, delta)를 변화시키면서 예측 성능을 비교하시오.

- ALPHA(smoothing level) : 수준(level)에 대한 weight

- BETA(smoothing trend) : 추세(trend)에 대한 weight
- GAMMA(smoothing seasonal) : 계절성(seasonal)에 대한 weight

파라미터 조합을 (Low : 0.1 , Medium : 0.5 , High : 0.9)로 진행해보겠다. 그리고 그 결과로 나오는 MAPE 값을 기준으로 상위 5 개의 parameter 조합을 두개의 HW 모델에 대해 각각 살펴보겠다.

=== Additive HW 상위 5개 결과 ===			
Alpha	Beta	Gamma	MAPE(%)
0.1	0.1	0.9	3.60
0.1	0.9	0.5	3.79
0.1	0.5	0.5	3.98
0.1	0.1	0.5	4.34
0.1	0.1	0.1	5.53
=== Multiplicative HW 상위 5개 결과 ===			
Alpha	Beta	Gamma	MAPE(%)
0.1	0.1	0.9	3.16
0.1	0.1	0.1	3.21
0.1	0.1	0.5	3.30
0.1	0.5	0.1	3.64
0.1	0.5	0.5	4.54

이는 아까 4 번에서 statmodels package 의 exponential smoothing 함수를 통해 구해낸 최적파라미터조합보다 significant 하게 우수해진 MAPE 값을 보여준다.

자동 최적화(optimized=True) 모델이 수동 Grid Search 모델보다 높은 MAPE 를 기록한 이유는 **최적화 기준의 차이**에 기인한다. optimized=True 는 훈련 데이터(In-sample)의 잔차 제곱합(SSE)을 최소화하도록 설계된 반면, 수동 탐색은 테스트 데이터(Out-of-sample)의 예측 오차율(MAPE)을 직접 타격하여 파라미터를 선정했기 때문이다.

이는 실제 비즈니스 예측 환경에서 과거 데이터에 대한 과도한 적합(Overfitting)보다, **적절한 가중치 조절을 통한 일반화 성능(Generalization) 확보**가 더 중요함을 시사한다. 따라서 이 과제에서는 실무적 예측력을 극대화하기 위해 테스트 데이터에서 검증된 최적 가중치를 최종 모델로 제안한다.

#6. 수업시간에 배운 절차에 따라 ARIMA 모델링을 수행하고, 최소 10 시점 이상에 대한 예측 성능을 평가하시오.

Box-Jenkins Procedure 의 절차를 이 데이터셋에 적용하면 다음과 같다.

전처리(Step 1): Stationarity 확인, differencing , 원본 데이터가 우상향 추세와 계절성을 보이므로, 단순 차분(d=1)과 계절 차분(D=1)을 통해 평균을 일정하게 만드는 과정.

최적 모델 결정(Step 2): ACF/PACF 패턴으로 후보를 좁힌 뒤, 최종적으로는 **AIC**(Akaike Information Criterion)가 가장 낮은 모델을 선택하여 간결성과 적합도를 동시에 확보. - 5 번과의 차이점

잔차 진단(Step 4): 수업 시간에 배운 대로 e_i 의 3sigma 라인을 신뢰 구간으로 설정. ACF 그래프에서 대부분의 막대가 이 파란 영역 안에 있다면 "모델이 적절하다(Adequate)"고 판단할 수 있다.


예측 성능 평가(Step 5): 테스트 데이터 12 시점에 대해 원래 스케일로 역변환하여 MAPE 를 산출함으로써 비즈니스 관점의 정확도를 측정.

Step1) Preprocessing

Check Stationarity !


-ACF 의 stationarity 판단 기준

1. 평균 주위에서 일정한 진동이 이루어지는가
2. 시간에 관계없이 분산의 폭이 일정한가
3. slowly dying down 이 아닌 cutoff 가 나타나는가 (stationary 는 큰 lag 값에 매우작은 ACF 가짐)



ACF plot 을 보면 값들이 slowly dying down 패턴을 가지므로 **unstationary** 함을 알 수 있다 -> Differencing 필요


1 차 differencing 후 Y_t 와 ACF plot:



Differencing 된 Y_t 는 0을 기준으로 일정한 폭의 분산을 가지는 것으로 보인다. ACF를 보더라도 특별한 pattern이 보이지 않아 2차차분은 필요하지 않아 보인다.

하지만 Lag 12마다 우뚝솟아오르는 데이터가 보이는데 이는 $d=1$ 으로 제거되지 않은 **12개월 주기의 계절적 패턴**이 남아있는 것이다. 따라서 계절 differencing이 필요하다.

Seasonal differencing 후 Y_t 와 ACF/PACF plot



- 1) 평균 0 을 기준으로 일정한 진폭을 보인다
- 2) 분산의 폭이 lag 가 커지더라도 일정하다
- 3) 후반 lag 에서 매우 작은 ACF 값을 가져 dying down fairly quickly.

=> **stationary**

Step2,3) Parameter Estimation + Determination of Model

```
=== Determination of Model (Top 5 AIC Results) ===
```

Model	AIC
ARIMA (0, 1, 1)x(0, 1, 0, 12)	-114.126711
ARIMA (1, 1, 1)x(0, 1, 0, 12)	-112.127153
ARIMA (1, 1, 0)x(0, 1, 0, 12)	-99.354868
ARIMA (0, 1, 0)x(0, 1, 0, 12)	-96.588108
ARIMA (0, 1, 1)x(1, 1, 0, 12)	-79.760605

```
-----  
🏆 [최적 모델 결정] Determine the model that renders the minimum AIC value:  
최적 파라미터: ARIMA (0, 1, 1) x (0, 1, 0, 12)  
Minimum AIC: -114.1267
```

AIC 값을 최소화하면서 파라미터 개수도 적은 우수한 parameter set 을 찾았다.

비계절성 부분 (0, 1, 1) :

d=1: 데이터의 추세를 제거하기 위해 1 차 차분을 수행함.

q=1: 바로 전의 오차항이 현재 값에 영향을 주는 MA(1) 구조임.


계절성 부분 (0, 1, 1, 12) :

D=1: 12 개월 주기의 계절성을 제거하기 위해 계절 차분을 수행함.

s=12: 월별 데이터의 특성을 반영한 12 개월 주기임.

Step4) Diagnosis Check

위에서 찾은 최적 모델의 ACF plot of the residual values 를 살펴보면 mostly 3 sigma line 안에 들어와있는 것을 알 수 있다. 이 모델의 **adequacy** 를 확인 했으므로 최종 모델로 선정




Step 5) Forecast

```
=== Forecasting Results (95% Confidence Limits) ===
```

Period	Forecast	Lower	Upper
2025-07	42609.497791	38573.614262	47067.648099
2025-08	57174.163290	51758.744760	63156.186710
2025-09	58748.751092	53184.190861	64895.520623
2025-10	91209.818598	82570.613171	100752.927576
2025-11	83569.427408	75653.904037	92313.136859
2025-12	89422.243074	80952.353105	98778.321442
2026-01	94218.813507	85294.602304	104076.747871
2026-02	86547.995500	78350.348317	95603.346837
2026-03	64008.243818	57945.515311	70705.304021
2026-04	63389.927421	57385.764565	70022.294361
2026-05	43347.348113	39241.576927	47882.698290
2026-06	43582.069276	39454.065787	48141.977880

```
-----
```



최종 확정된 SARIMA 모델을 활용하여 위와 같이 향후 12 시점의 수요를 예측하였으며, 점 예측값(Point Forecast)과 함께 예측의 불확실성을 고려한 95% 신뢰 구간을 도출하였다.

Conclusion)

1. 수요의 추세 및 계절성 동기화 (Trend & Seasonality Alignment)

- **인사이트:** SARIMA 모델은 과거 데이터에서 나타난 **장기적인 추세**와 **12개월 주기성**을 파라미터($d=1$, $D=1$)를 통해 정확히 추출해냈다.
- **의미:** 예측 그래프의 굴곡이 과거 패턴과 유사하게 움직이는 것은, 모델이 단순 평균이 아니라 실제 수요가 발생하는 '계절적 리듬'을 성공적으로 학습했음을 의미한다.

2. 예측의 불확실성과 리스크 관리 (Managing Uncertainty)

- **인사이트:** 중앙의 빨간 점선(Point Forecast)은 가장 확률이 높은 기대치이나, 옅은 빨간 영역인 95% 신뢰 구간(95% Confidence Interval)은 실제 수요가 존재할 수 있는 통계적 범위를 보여준다.

- **의미:** 예측 시점이 멀어질수록 신뢰 구간이 조금씩 넓어지는데, 이는 미래로 갈수록 불확실성이 증가하므로 장기 계획 수립 시 더 높은 수준의 **유연성**이 필요함을 시사한다.

3. 운영 및 생산 계획의 근거 (Operational Decision Support)

- **인사이트:** 95% 신뢰 구간의 **상한선(Upper Bound)** 수치는 **안전 재고(Safety Stock)**를 산정하는 결정적인 기준이 된다.
- **의미:** 단순히 평균 예측값에 맞춰 생산량을 정하는 것이 아니라, 수요 변동의 상한치를 고려하여 품질 리스크를 최소화하는 최적 재고 수준을 결정할 수 있다.

4. 모델의 신뢰성 및 적정성 (Model Reliability)

- **인사이트:** 앞선 **Diagnosis Check** 단계에서 잔차가 백색 잡음(White Noise)임을 확인했기 때문에, 현재의 예측치는 데이터 속의 시계열 정보를 남김없이 반영한 결과다.
- **의미:** 다른 주관적인 판단이나 단순 이동평균법보다 통계적으로 훨씬 정교하고 신뢰할 수 있는 수치이며, 이를 경영 의사결정의 객관적 지표로 활용할 정당성이 확보되었다.